

Задача 1 (2.5 балла).

Для начала напомним, как выглядит кусочно-постоянная функция потерь из SVM:

$$L(y, z) = \max(0, 1 - yz)$$

Ответьте на вопросы о функциях потерь и линейных моделях:

1. В функции потерь для SVM отсечка в точке $yz = 1$ беспокоит нас. Мы решили поэкспериментировать и воспользоваться функцией потерь $\tilde{L} = \max(0, -1 - yz)$. Что получится, если мы обучим модель на такую функцию?
2. Мы продолжаем эксперименты и хотим сделать два «излома»: $\hat{L} = \min(\max(0, 1 - yz), 10)$. Что будет при обучении на эту функцию потерь?
3. Рассмотрим обобщённую задачу метода опорных векторов:

$$\begin{cases} \|w\|^p + C \sum_{i=1}^{\ell} \xi_i^q \rightarrow \min_{w, b, \xi} \\ y_i(\langle w, x_i \rangle + b) \geq 1 - \xi_i, \quad i = 1, \dots, \ell, \\ \xi_i \geq 0, \quad i = 1, \dots, \ell. \end{cases} \quad (0.1)$$

Считайте, что $p > 0$, $q > 0$. Ответьте на вопросы:

- Запишите эту задачу оптимизации в безусловном виде.
- Как гиперпараметры p и q влияют на задачу? Опишите, как будет меняться решение при уменьшении и увеличении каждого из этих гиперпараметров.

1.

Введём обозначение отступа: $M = yz$. Стандартный Hinge loss записывается через отступ как $L(M) = \max(0, 1 - M)$ и равен нулю при $M \geq 1$, то есть модель перестаёт штрафовать объекты, классифицированные верно с отступом не менее 1.

Новая функция потерь:

$$\tilde{L}(M) = \max(0, -1 - M)$$

Эта функция равна нулю при $M \geq -1$. Значит, модель не штрафует объекты с отступом $M \in [-1, +\infty)$.

Как следствие все объекты, классифицированные верно ($M > 0$), а также объекты с небольшими ошибками (отрицательный отступ $M \in [-1, 0)$) не вносят никакого вклада в функционал ошибки. Модель начинает штрафовать только объекты с $M < -1$, то есть те, которые классифицированы неверно и при этом находятся далеко за разделяющей гиперплоскостью.

Хорошая функция потерь должна штрафовать за неправильные ответы и за неуверенную классификацию. Здесь же модель допускает ошибки с отступом до -1 без какого-либо штрафа, что означает, что разделяющая гиперплоскость может проходить так, что часть объектов будет классифицирована неверно, но модель не будет стремиться это исправить.

Вывод: При обучении на $\tilde{L}$ модель будет существенно хуже разделять классы по сравнению со стандартным SVM, поскольку допускает грубые ошибки без штрафа.

2.

Запишем через отступ $M = yz$:

$$\hat{L}(M) = \min(\max(0, 1 - M), 10)$$

Поведение по трём областям:

Область	Значение $\hat{L}$	Производная
$M \geq 1$	0	0
$-9 \leq M < 1$	$1 - M$	-1
$M < -9$	10	0

При $M \leq -9$ (грубо неверно классифицированные объекты) штраф перестаёт расти и фиксируется на уровне 10. Градиент в этой области равен нулю.

Функция потерь считается устойчивой к выбросам, если её производная ограничена при $M \rightarrow -\infty$. У стандартного Hinge loss производная равна -1 при $M < 1$ — она ограничена, но штраф растёт неограниченно. У $\hat{L}$ штраф ограничен числом 10.

В следствие этого модель становится *устойчивой к сильным выбросам*. Объекты с очень большим отрицательным отступом ($M < -9$) не влияют на веса при обучении, из-за нулевого градиента. Обычный SVM пытался бы существенно изменить веса, чтобы уменьшить огромный штраф на таких объектах. Ограниченный SVM просто «заплатит» фиксированный штраф 10 и проигнорирует выброс, сосредоточившись на основной массе данных.

3.

Безусловный вид

Из ограничений задачи (0.1):

$$\xi_i \geq 1 - y_i(\langle w, x_i \rangle + b), \quad \xi_i \geq 0$$

Поскольку мы минимизируем $\sum \xi_i^q$ (а $q > 0$), то оптимальное значение:

$$\xi_i = \max(0, 1 - y_i(\langle w, x_i \rangle + b))$$

Подставляем в целевую функцию:

$$\|w\|^p + C \sum_{i=1}^{\ell} \left(\max(0, 1 - y_i(\langle w, x_i \rangle + b)) \right)^q \rightarrow \min_{w, b}$$

Влияние p

Параметр p определяет тип регуляризации:

- $p = 2$: стандартная L_2 -регуляризация. В SVM это эквивалентно максимизации ширины разделяющей полосы $2/\|w\|$. Веса стремятся быть небольшими, но ненулевыми
- $p = 1$: L_1 -регуляризация. Приводит к разреженности весов — многие компоненты вектора w обнуляются. Это реализует встроенный отбор признаков

- При $p \rightarrow 0$: штрафуются количество ненулевых весов (псевдонорма L_0). Модель стремится использовать минимальное число признаков

При увеличении p регуляризатор становится менее чувствительным к малым и средним весам, модель допускает больше таких весов, что может привести к переобучению. Большие веса штрафуются ещё сильнее, поэтому большие p приводят к решениям с равномерно небольшими, но ненулевыми весами. А при уменьшении p (особенно $p < 1$) регуляризатор всё сильнее поощряет разреженность, но задача оптимизации становится невыпуклой

Влияние q

Параметр q определяет степень штрафа за нарушение отступа:

- $q = 1$: стандартный Hinge loss. Линейный штраф за нарушение отступа. Производная ограничена, функция устойчива к выбросам
- $q = 2$: квадратичный Hinge loss. Сильнее штрафует за большие ошибки: если отступ нарушен на 2, то при $q = 1$ штраф равен 2, а при $q = 2$ штраф равен 4. Менее устойчив к выбросам
- $q < 1$ (например, $q = 0.5$): штраф растёт медленнее линейного. Производная $q\xi^{q-1}$ стремится к бесконечности при $\xi \rightarrow 0$, но при больших ξ штраф растёт медленно. Это повышает устойчивость к объектам с большими нарушениями отступа

При увеличении q модель всё сильнее подгоняется под выбросы, поскольку квадрат и более высокие степени ошибки доминируют в функционале (аналогия с MSE vs MAE). При уменьшении q модель становится более робастной, аналогично тому, как MAE устойчивее MSE к выбросам, но задача теряет выпуклость

Задача 2 (2.5 балла)

Ответьте на вопросы по решающим деревьям и композициям:

1. На лекциях обсуждалось, что решающие деревья можно использовать для генерации нелинейных признаков: берём дерево и используем номер листа, куда попал объект, как значение нового категориального признака. При этом можно воспользоваться деревом, обученным привычным нам способом на всей обучающей выборке, а можно взять случайное дерево (где все предикаты выбирались случайно, без оптимизации какого-либо критерия). Удивительно, но последний способ используют чаще при генерации признаков. Чем это можно объяснить? А что нужно сделать с обучаемыми деревьями, чтобы их тоже было удобно использовать для генерации признаков?
2. Иногда в Random Forest используют дополнительную рандомизацию: при построении вершины выбирается (как обычно) случайное подмножество признаков, для каждого признака оттуда генерируется случайный набор порогов, и лучший предикат ищется только среди этих признаков и порогов. Как это изменение влияет на смещение и разброс композиции? Обоснуйте ваш ответ (здесь предполагаются рассуждения, а не строгий формальный вывод).

3. Представьте, что мы решили обучать градиентный бустинг так:

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (b_N(x_i) - s_i[|s_i| \geq 0.1])^2 \rightarrow \min_{b_N}; \quad s_i = - \left. \frac{\partial L(y_i, z)}{\partial z} \right|_{z=a_{N-1}(x_i)}$$

Для конкретики будем считать, что используется логистическая функция потерь $L(y, z) = \log(1 + \exp(-yz))$. Как эта модификация повлияет на обучение для первых базовых моделей в композиции? А для более поздних базовых моделей?

1.

Номер листа дерева $T_n(x)$ является ценным категориальным признаком, который задаёт нелинейное разбиение пространства и несёт информацию о сходстве объектов.

Почему случайные деревья используют чаще:

Случайные деревья строятся очень быстро, так как не нужно оптимизировать критерий информативности и при этом генерируют *разнообразные* слабо коррелированные признаки за счёт случайности структуры, так каждое случайное дерево даёт своё уникальное разбиение пространства.

Обучаемые деревья, наоборот, *жадные*: при обучении на одной и той же выборке они будут строить очень похожие разбиения, оптимизируя одни и те же критерии. Дисперсия ансамбля:

$$\text{Var}(a) = \rho \sigma^2 + \frac{1 - \rho}{N} \sigma^2$$

корреляция ρ между обучаемыми деревьями будет высокой, а разнообразие признаков — низким.

Более того, обучаемые деревья, построенные на той же выборке, на которой потом обучается финальная модель, содержат информацию о целевой переменной. Это приводит к «утечке» целевой переменной в значения признаков как со стекингом, что может вызвать переобучение.

Что нужно сделать с обучаемыми деревьями:

Чтобы обучаемые деревья давали разнообразные и некоррелированные признаки, к ним нужно применить рандомизацию:

- Обучать каждое дерево на бутстрапированной подвыборке как в бэггинге
- Использовать случайный выбор признаков при каждом разбиении как в Random Forest
- Обучать деревья на одной части выборки, а использовать признаки — на другой (аналогия с кросс-валидацией при стекинге)

Это уменьшит корреляцию ρ между деревьями и предотвратит утечку целевой переменной.

2.

При случайном выборе порога вместо оптимального каждое дерево строится хуже, так как меньше подстраивается под обучающую выборку.

Смещение каждого отдельного дерева *увеличивается*, поскольку порог выбирается не оптимально — дерево хуже описывает закономерности в данных.

Разброс: Случайность порогов делает деревья менее похожими друг на друга, то есть уменьшает корреляцию ρ :

$$\text{Var}(a) = \rho \sigma^2 + \frac{1 - \rho}{N} \sigma^2$$

уменьшение ρ при фиксированном N снижает дисперсию ансамбля.

Это типичный bias-variance trade-off. Рандомизация порогов немного увеличивает смещение каждого дерева, но значительно снижает разброс всего ансамбля за счёт декорреляции деревьев. Поскольку бэггинг не меняет смещение композиции, а снижает разброс, дополнительная рандомизация усиливает этот эффект.

3.

Стандартная процедура градиентного бустинга где сдвиги вычисляются как анти-градиент функции потерь:

$$s_i = - \left. \frac{\partial L(y_i, z)}{\partial z} \right|_{z=a_{N-1}(x_i)}$$

Для логистической функции потерь $L(y, z) = \log(1 + \exp(-yz))$ антиградиент равен:

$$s_i = \frac{y_i}{1 + \exp(y_i a_{N-1}(x_i))}$$

Значит, $|s_i| \leq 1$, при этом $|s_i|$ близок к 1, когда объект сильно ошибочно классифицирован, и близок к 0, когда объект уверенно верно классифицирован.

Модификация: Вместо обучения на все сдвиги s_i , базовая модель обучается на $s_i[|s_i| \geq 0.1]$. Это означает, что если $|s_i| < 0.1$, то целевое значение для данного объекта обнуляется — базовая модель не пытается его сдвинуть, иначе остается как есть.

Первые базовые модели:

На старте композиция ещё не обучена ($a_0(x)$ — простая константа), поэтому ошибки на большинстве объектов велики. Для логистических потерь:

$$|s_i| = \frac{1}{1 + \exp(y_i a_0(x_i))}.$$

При $a_0(x) = 0$ получаем $|s_i| = 0.5$ для всех объектов, что значительно больше порога 0.1. Следовательно, для первых моделей $[|s_i| \geq 0.1] = 1$ почти для всех объектов, и обучение практически не отличается от стандартного.

Поздние базовые модели:

По мере добавления деревьев композиция становится всё точнее. Для объектов, которые уже хорошо классифицированы (большой положительный отступ $y_i a_{N-1}(x_i) \gg 0$):

$$|s_i| = \frac{1}{1 + \exp(y_i a_{N-1}(x_i))} \approx 0$$

Для таких объектов $|s_i| < 0.1$ и их сдвиг обнуляется. Базовая модель перестаёт обращать на них внимание и фокусируется только на объектах, где $|s_i| \geq 0.1$ — то есть на объектах, которые модель ещё не научилась классифицировать уверенно.

Проблема: На поздних итерациях объектов с $|s_i| \geq 0.1$ становится мало. Среди них окажутся преимущественно:

- Выбросы — шумовые объекты с неверными метками
- Объекты вблизи границы классов.

Базовая модель будет обучаться только на этих «трудных» объектах, что может привести к **переобучению на выбросах**: модель начнёт подстраиваться под шум, ухудшая качество на основной массе данных (по аналогии с проблемой экспоненциальной функции потерь)

Задача 3 (2.5 балла)

Мы столкнулись с очень необычной задачей бинарной классификации: в выборке ℓ объектов, и лишь один из них относится к положительному классу. Модели обучать будет нелегко, но зато мы можем существенно упростить подсчёт метрик качества. Обозначим за $b(x)$ модель, выдающую уверенность в том, что x относится к положительному классу.

Выполните следующие задания:

1. Пусть $k \in \{0, 1, \dots, \ell-1\}$ — позиция положительного объекта в выборке, ранжированной по уверенности модели. Иными словами, k объектов имеют большее значение $b(x)$, чем положительный объект. Запишите формулу для AUC-ROC в зависимости от k .
2. Рассмотрим теперь новую метрику — площадь под FNR/FPR кривой. По оси x откладывается $FNR = \frac{FN}{FN+TP}$, по оси y откладывается $FPR = \frac{FP}{FP+TN}$. Запишите формулу для зависимости площади под этой кривой от k .

1.

В выборке 1 положительный объект и $\ell - 1$ отрицательных. Всего пар (положительный, отрицательный):

$$\ell_+ \cdot \ell_- = 1 \cdot (\ell - 1) = \ell - 1$$

По аналитической формуле AUC-ROC:

$$\text{AUC-ROC} = \frac{1}{\ell_+ \ell_-} \sum_{i: y_i=1} \sum_{j: y_j=-1} \left([b(x_i) > b(x_j)] + \frac{1}{2} [b(x_i) = b(x_j)] \right)$$

Поскольку $\ell_+ = 1$, внешняя сумма содержит лишь одно слагаемое. По условию, k отрицательных объектов имеют оценку *выше*, чем положительный объект. Значит, для них $b(x_i) < b(x_j)$ — это неправильно упорядоченные пары. Правильно упорядоченных пар: $(\ell - 1) - k$.

Предполагая отсутствие равных оценок, что согласуется с условием:

$$\text{AUC-ROC} = \frac{(\ell - 1) - k}{\ell - 1} = 1 - \frac{k}{\ell - 1}$$

Проверка:

- При $k = 0$ — положительный объект на первом месте: $AUC = 1$
- При $k = \ell - 1$ — положительный объект на последнем месте: $AUC = 0$

2.

Кривая строится в осях: ось x — FNR, ось y — FPR. Их определения:

$$FNR = \frac{FN}{FN + TP} = \frac{FN}{\ell_+}, \quad FPR = \frac{FP}{FP + TN} = \frac{FP}{\ell_-}$$

Поскольку $\ell_+ = 1$ и $\ell_- = \ell - 1$:


$$FNR \in \{0, 1\}, \quad FPR \in \left\{0, \frac{1}{\ell - 1}, \frac{2}{\ell - 1}, \dots, 1\right\}$$

Построение кривой. Сортируем объекты по убыванию $b(x)$, при пороге выше максимального $b(x)$ все прогнозы отрицательные: $FP = 0$, $FN = 1$, тогда начальная точка: $(FNR, FPR) = (1, 0)$

При понижении порога:

- Если проходим отрицательный объект: FP растёт на 1, FPR растёт на $\frac{1}{\ell - 1}$ - шаг вверх
- Если проходим положительный объект: FN падает до 0, FNR падает до 0 - шаг влево

В конце — $(FNR, FPR) = (0, 1)$.



$$\text{Площадь под FNR/FPR кривой} = \frac{k}{\ell - 1} = 1 - \text{AUC-ROC}.$$

Задача 4 (2.5 балла).

Напомним, что разложение ошибки на шум, смещение и разброс выглядит так:

$$L(\mu) = \underbrace{\mathbb{E}_{x,y} \left[(y - \mathbb{E}[y | x])^2 \right]}_{\text{шум}} + \underbrace{\mathbb{E}_x \left[(\mathbb{E}_X[\mu(X)] - \mathbb{E}[y | x])^2 \right]}_{\text{смещение}} + \underbrace{\mathbb{E}_x \left[\mathbb{E}_X \left[(\mu(X) - \mathbb{E}_X[\mu(X)])^2 \right] \right]}_{\text{разброс}}$$

Допустим, у нас есть обучающая выборка из двух объектов, в которой данные описываются одним бинарным признаком x , который принимает значение 1 с вероятностью p и значение 0 с вероятностью $1 - p$. Целевая переменная имеет нормальное распределение со средним x и дисперсией σ^2 , $y \sim \mathcal{N}(x, \sigma^2)$. Метод обучения выдаёт модель, предсказывающую среднее по выборке: $\mu(X)(x) = \frac{x_1 + x_2}{2}$. Найдите шум, смещение и разброс описанного метода обучения.

Решение

Истинная зависимость $\mathbb{E}[y | x]$

По условию, $y \sim \mathcal{N}(x, \sigma^2)$, следовательно $\mathbb{E}[y | x] = x$

Шум $\text{Var}(y | x)$

$$\text{Шум} = \mathbb{E}_{x,y} [(y - \mathbb{E}[y | x])^2] = \mathbb{E}_x [\text{Var}(y | x)]$$

Из условия $y \sim \mathcal{N}(x, \sigma^2)$:

$$\text{Var}(y | x) = \sigma^2$$

Эта величина не зависит от x , поэтому:

$$\text{Шум} = \sigma^2$$

Средний прогноз модели $\mathbb{E}_X[\mu(X)(x)]$

$$\mu(X)(x) = \frac{x_1 + x_2}{2}$$

Прогноз модели **не зависит** от тестового объекта x , ведь он определяется только обучающей выборкой (x_1, x_2)

Берём матожидание по случайности обучения (x_1 и x_2 — независимые случайные величины с распределением $\text{Ber}(p)$):

$$\mathbb{E}_X[\mu(X)(x)] = \mathbb{E}_{x_1, x_2} \left[\frac{x_1 + x_2}{2} \right] = \frac{\mathbb{E}[x_1] + \mathbb{E}[x_2]}{2}$$

Поскольку $x \sim \text{Ber}(p)$, то $\mathbb{E}[x] = p$:

$$\mathbb{E}_X[\mu(X)(x)] = \frac{p + p}{2} = p$$

Смещение

$$\text{Bias}(x) = \mathbb{E}_X[\mu(X)(x)] - \mathbb{E}[y \mid x] = p - x$$

Квадрат смещения:

$$\text{Bias}^2(x) = (p - x)^2$$

Усредняем по тестовому $x \sim \text{Ber}(p)$:

$$\mathbb{E}_x[\text{Bias}^2(x)] = \mathbb{E}_x[(x - p)^2] = \text{Var}(x)$$

Для бернуллиевской случайной величины $\text{Var}(x) = p(1 - p)$:

$$\text{Смещение}^2 = p(1 - p)$$

Разброс $\text{Var}_X(\mu(X)(x))$

$$\text{Var}_X(\mu(X)(x)) = \text{Var}_{x_1, x_2} \left(\frac{x_1 + x_2}{2} \right) = \frac{1}{4} (\text{Var}(x_1) + \text{Var}(x_2))$$

Поскольку x_1, x_2 независимы и одинаково распределены, $\text{Var}(x_i) = p(1 - p)$:

$$\text{Var}_X(\mu(X)(x)) = \frac{1}{4} (p(1 - p) + p(1 - p)) = \frac{p(1 - p)}{2}$$

Разброс не зависит от x , поэтому усреднение по x не меняет результат:

$$\text{Разброс} = \frac{p(1 - p)}{2}$$

$$\text{Шум} = \sigma^2, \quad \text{Смещение}^2 = p(1 - p), \quad \text{Разброс} = \frac{p(1 - p)}{2}$$

- **Шум** = σ^2 : неустраняемая ошибка, обусловленная случайностью y при фиксированном x
- **Смещение** = $p(1 - p)$: Средний прогноз модели ($= p$) не совпадает с истинной зависимостью ($= x$). Это объясняется тем, что модель предсказывает среднее по обучающей выборке, которое не зависит от конкретного тестового объекта x . Смещение тем больше, чем более «сбалансирован» признак (p близко к 0.5)
- **Разброс** = $p(1 - p)/2$: Прогноз модели зависит от обучающей выборки через $x_1 + x_2$. При N объектах в выборке разброс был бы $p(1 - p)/N$
- Полная ошибка:

$$L(\mu) = \sigma^2 + p(1 - p) + \frac{p(1 - p)}{2} = \sigma^2 + \frac{3}{2}p(1 - p)$$